#### Алгоритмические свойства сжатых текстов

Анна Козлова, Евгений Курпилянский, Алексей Хворост

28 ноября 2011 года

С ростом размера входных данных для классических задач меняются алгоритмы, способные их эффективно решать.

#### Существует несколько подходов, например:

- Алгоритмы эффективного ввода-вывода алгоритмы, минимизирующие чтение данных с жесткого диска.
- Сокращение размера входа за счет предварительной обработки.

С ростом размера входных данных для классических задач меняются алгоритмы, способные их эффективно решать.

Существует несколько подходов, например:

- Алгоритмы эффективного ввода-вывода алгоритмы, минимизирующие чтение данных с жесткого диска.
- Сокращение размера входа за счет предварительной обработки.

С ростом размера входных данных для классических задач меняются алгоритмы, способные их эффективно решать.

Существует несколько подходов, например:

- Алгоритмы эффективного ввода-вывода алгоритмы, минимизирующие чтение данных с жесткого диска.
- Сокращение размера входа за счет предварительной обработки.

## Определение прямолинейной программы

#### Определение

**Прямолинейная программа** (ПП)  $\mathcal{X}$  размера n – это последовательность правил вывода

$$\mathcal{X}_1 = expr_1, \mathcal{X}_2 = expr_2, \dots, \mathcal{X}_n = expr_n,$$

где  $\mathcal{X}_i$  — это переменные, а  $expr_i$  — это выражения вида:

- $expr_i$  символ из алфавита  $\Sigma$  (терминальные правила).
- ullet  $expr_i = \mathcal{X}_l \cdot \mathcal{X}_r \ (l, r < i) \ (нетерминальные правила).$

**Прямолинейная программа** — это грамматика, выводящая в точности одно слово.

# Определение прямолинейной программы

#### Определение

**Прямолинейная программа** (ПП)  ${\cal X}$  размера n — это последовательность правил вывода

$$\mathcal{X}_1 = expr_1, \mathcal{X}_2 = expr_2, \dots, \mathcal{X}_n = expr_n,$$

где  $\mathcal{X}_i$  – это **переменные**, а  $expr_i$  – это **выражения** вида:

- $expr_i$  символ из алфавита  $\Sigma$  (терминальные правила).
- ullet  $expr_i = \mathcal{X}_l \cdot \mathcal{X}_r \ (l, r < i) \ ($ нетерминальные правила).

**Прямолинейная программа** — это грамматика, выводящая в точности одно слово.

#### Пример

Рассмотрим ПП  $\mathcal{X}$ , выводящую строку X= «abaababaabaab».

$$\mathcal{X}_1 = b$$

$$\mathcal{X}_2 = a$$

$$\mathcal{X}_3 = \mathcal{X}_2 \cdot \mathcal{X}_1$$

$$\mathcal{X}_4 = \mathcal{X}_3 \cdot \mathcal{X}_2$$

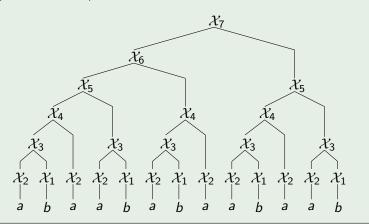
$$\mathcal{X}_5 = \mathcal{X}_4 \cdot \mathcal{X}_3$$

$$\mathcal{X}_6 = \mathcal{X}_5 \cdot \mathcal{X}_4$$

$$\mathcal{X}_7 = \mathcal{X}_6 \cdot \mathcal{X}_5$$

#### Пример

Графическое изображение ПП:



### ПП – это способ сжатия данных

Длина строки, выводимой из ПП, может быть экспоненциальной относительно размеров ПП.

#### Недостатки

Сжатие с помощью ПП значительно уступает стандартным алгоритмам сжатия.

#### Преимущества

Есть возможность осуществлять различные алгоритмы над  $\Pi\Pi$ , не распаковывая данные.

## ПП – это способ сжатия данных

Длина строки, выводимой из ПП, может быть экспоненциальной относительно размеров ПП.

#### Недостатки

Сжатие с помощью ПП значительно уступает стандартным алгоритмам сжатия.

#### Преимущества

Есть возможность осуществлять различные алгоритмы над  $\Pi\Pi$ , не распаковывая данные.

### ПП – это способ сжатия данных

Длина строки, выводимой из ПП, может быть экспоненциальной относительно размеров ПП.

#### Недостатки

Сжатие с помощью ПП значительно уступает стандартным алгоритмам сжатия.

#### Преимущества

Есть возможность осуществлять различные алгоритмы над ПП, не распаковывая данные.

# Алгоритмы над ПП

Существует ряд классических задач, сформулированных в терминах ПП и разрешимых за полиномиальное время от размера ПП, например:

- Поиск сжатого образца в сжатом тексте
- Поиск наибольшей общей подстроки двух сжатых строк
- Поиск палиндромов в сжатой строке
- Поиск квадратов в сжатой строке

# Алгоритмы над ПП

Существует ряд классических задач, сформулированных в терминах ПП и разрешимых за полиномиальное время от размера ПП, например:

- Поиск сжатого образца в сжатом тексте
- Поиск наибольшей общей подстроки двух сжатых строк
- Поиск палиндромов в сжатой строке
- Поиск квадратов в сжатой строке

#### Главный вопрос

Осмысленно ли использование прямолинейных программ на практике?

- Насколько сложна задача построения ПП?
- Насколько сжатие с использованием ПП уступает классическим алгоритмам сжатия?

#### Главный вопрос

Осмысленно ли использование прямолинейных программ на практике?

- Насколько сложна задача построения ПП?
- Насколько сжатие с использованием ПП уступает классическим алгоритмам сжатия?

#### Главный вопрос

Осмысленно ли использование прямолинейных программ на практике?

- Насколько сложна задача построения ПП?
- Насколько сжатие с использованием ПП уступает классическим алгоритмам сжатия?

# Как строить ПП?

#### Утверждение. W.Rytter et al. 2003

Задача построения минимальной ПП, выводящей заданную строку T – NP-полная.



Для построения ПП требуется использовать приближенные алгоритмы.

# Как строить ПП?

#### Утверждение. W.Rytter et al. 2003

Задача построения минимальной ПП, выводящей заданную строку T – NP-полная.



Для построения ПП требуется использовать приближенные алгоритмы.

#### Идея

Для построения ПП в качестве отправной точки использовать классические алгоритмы сжатия.

Оказалось, что классический алгоритм Лемпеля-Зива хорошо подходит для этой задачи.

#### Идея

Для построения ПП в качестве отправной точки использовать классические алгоритмы сжатия.

Оказалось, что классический алгоритм Лемпеля-Зива хорошо подходит для этой задачи.

#### Определение

**Факторизация** строки T – это набор строк  $F_1, F_2, \ldots, F_k$  такой, что  $T = F_1 \cdot F_2 \cdot \ldots \cdot F_k$ .

#### Определение

LZ-факторизация строки T — это набор строк  $F_1, F_2, \ldots, F_k$ , где

- $F_1 = T[0];$
- $F_i$  равен наибольшему префиксу  $T[|F_1 \cdot \ldots \cdot F_{i-1}| \ldots |T|-1]$ , который встречался в тексте ранее или  $T[|F_1 \cdot \ldots \cdot F_{i-1}|]$  в случае, если этот префикс пустой.

#### Факторизации строки «abaababaabaab»

- a · b · a · aba · baaba · ab:

#### Определение

**Факторизация** строки T – это набор строк  $F_1, F_2, \ldots, F_k$  такой, что  $T = F_1 \cdot F_2 \cdot \ldots \cdot F_k$ .

#### Определение

LZ-факторизация строки T – это набор строк  $F_1, F_2, \ldots, F_k$ , где

- $F_1 = T[0]$ ;
- $F_i$  равен наибольшему префиксу  $T[|F_1 \cdot \ldots \cdot F_{i-1}| \ldots |T|-1]$ , который встречался в тексте ранее или  $T[|F_1 \cdot \ldots \cdot F_{i-1}|]$  в случае, если этот префикс пустой.

#### Факторизации строки «abaababaabaab»

- a · b · a · aba · baaba · ab:

#### Определение

**Факторизация** строки T — это набор строк  $F_1, F_2, \ldots, F_k$  такой, что  $T = F_1 \cdot F_2 \cdot \ldots \cdot F_k$ .

#### Определение

LZ-факторизация строки T – это набор строк  $F_1, F_2, \ldots, F_k$ , где

- $F_1 = T[0];$
- $F_i$  равен наибольшему префиксу  $T[|F_1 \cdot \ldots \cdot F_{i-1}| \ldots |T|-1]$ , который встречался в тексте ранее или  $T[|F_1 \cdot \ldots \cdot F_{i-1}|]$  в случае, если этот префикс пустой.

#### Факторизации строки «abaababaabaab»

- a·b·a·a·b·a·b·a·a·b·a·a·b;
- a · b · a · aba · baaba · ab:

# LZ-факторизацию строки T длины n можно построить как минимум двумя способами:

- За O(n) с использованием суффиксного дерева. Тяжело адаптируется на случай, когда заканчивается оперативная память.
- За  $O(n \log n)$  с использованием суффиксного массива. Проще в реализации, легко адаптируется на использование внешней памяти.

# LZ-факторизацию строки T длины n можно построить как минимум двумя способами:

- За O(n) с использованием суффиксного дерева. Тяжело адаптируется на случай, когда заканчивается оперативная память.
- За O(n log n) с использованием суффиксного массива.
   Проще в реализации, легко адаптируется на использование внешней памяти.

LZ-факторизацию строки T длины n можно построить как минимум двумя способами:

- За O(n) с использованием суффиксного дерева. Тяжело адаптируется на случай, когда заканчивается оперативная память.
- За O(n log n) с использованием суффиксного массива.
   Проще в реализации, легко адаптируется на использование внешней памяти.

# *LZ*77-факторизация

#### Определение

LZ77-факторизация строки T — это набор строк  $F_1, F_2, \ldots, F_k$ , где

- $F_1 = T[0]$ ;
- $F_i$  равен наибольшему префиксу  $T[|F_1 \cdot \ldots \cdot F_{i-1}| \ldots |T|-1]$ , который встречался в суффиксе уже просмотренного текста или  $T[|F_1 \cdot \ldots \cdot F_{i-1}|]$  в случае, если этот префикс пустой.

#### Недостатки

LZ77-факторизация содержит больше факторов, чем LZ-факторизация.

#### Преимущества

Алгоритм построения факторизации может работать в оперативной памяти.

#### Недостатки

LZ77-факторизация содержит больше факторов, чем LZ-факторизация.

#### Преимущества

Алгоритм построения факторизации может работать в оперативной памяти.

#### Постановка задачи

 $\mathrm{Bxo}$ Д: Строка T и ее факторизация  $F_1$ ,  $F_2$ , ...,  $F_k$ .

 $\mathrm{Выход}$ : ПП, выводящая строку T.

- Дерево разбора ПП представляется в виде AVL-дерева.
- Факторы обрабатываются последовательно.
- Необходимо уметь реализовывать операцию конкатенации двух ПП.
- Для эффективности реализации структура данных должна обладать свойством confluently persistent.
- Все вершины дерева должны быть неизменяемыми. Если требуется изменить вершину, создаем и изменяем копию этой вершины.
- Появляются много неиспользуемых вершин. ⇒ Необходим менеджер памяти, освобождающий ресурсы.

- Дерево разбора ПП представляется в виде AVL-дерева.
- Факторы обрабатываются последовательно.
- Необходимо уметь реализовывать операцию конкатенации двух ПП.
- Для эффективности реализации структура данных должна обладать свойством confluently persistent.
- Все вершины дерева должны быть неизменяемыми. Если требуется изменить вершину, создаем и изменяем копию этой вершины.
- Появляются много неиспользуемых вершин. ⇒ Необходим менеджер памяти, освобождающий ресурсы.

- Дерево разбора ПП представляется в виде AVL-дерева.
- Факторы обрабатываются последовательно.
- Необходимо уметь реализовывать операцию конкатенации двух ПП.
- Для эффективности реализации структура данных должна обладать свойством confluently persistent.
- Все вершины дерева должны быть неизменяемыми. Если требуется изменить вершину, создаем и изменяем копию этой вершины.
- Появляются много неиспользуемых вершин. ⇒ Необходим менеджер памяти, освобождающий ресурсы.

- Дерево разбора ПП представляется в виде AVL-дерева.
- Факторы обрабатываются последовательно.
- Необходимо уметь реализовывать операцию конкатенации двух ПП.
- Для эффективности реализации структура данных должна обладать свойством *confluently persistent*.
- Все вершины дерева должны быть неизменяемыми. Если требуется изменить вершину, создаем и изменяем копию этой вершины.
- Появляются много неиспользуемых вершин. ⇒ Необходим менеджер памяти, освобождающий ресурсы.

- Дерево разбора ПП представляется в виде AVL-дерева.
- Факторы обрабатываются последовательно.
- Необходимо уметь реализовывать операцию конкатенации двух ПП.
- Для эффективности реализации структура данных должна обладать свойством *confluently persistent*.
- Все вершины дерева должны быть неизменяемыми. Если требуется изменить вершину, создаем и изменяем копию этой вершины.
- Появляются много неиспользуемых вершин. ⇒ Необходим менеджер памяти, освобождающий ресурсы.

- Дерево разбора ПП представляется в виде AVL-дерева.
- Факторы обрабатываются последовательно.
- Необходимо уметь реализовывать операцию конкатенации двух ПП.
- Для эффективности реализации структура данных должна обладать свойством *confluently persistent*.
- Все вершины дерева должны быть неизменяемыми. Если требуется изменить вершину, создаем и изменяем копию этой вершины.
- Появляются много неиспользуемых вершин. ⇒ Необходим менеджер памяти, освобождающий ресурсы.

## Teopeмa. W.Rytter et al. 2003

Пусть дан текст T и его факторизация размера k. Тогда алгоритм Риттера позволяет построить ПП  $\mathcal{T}$  размером  $O(k \cdot \log |T|)$  за время  $O(k \cdot \log |T|)$ .

#### Преимущества

- Размер полученной ПП всего в  $O(\log n)$  больше размера минимальной ПП
- AVL-дерево «сильносбалансированное» дерево, его высота ограничена сверху  $\frac{1+\sqrt{5}}{2}\log n$ .

#### Недостатки

• Операция перебалансировки узла является достаточно дорогой операцией, обновляется три вершины.

#### Преимущества

- Размер полученной ПП всего в  $O(\log n)$  больше размера минимальной ПП
- AVL-дерево «сильносбалансированное» дерево, его высота ограничена сверху  $\frac{1+\sqrt{5}}{2}\log n$ .

### Недостатки

• Операция перебалансировки узла является достаточно дорогой операцией, обновляется три вершины.

#### Преимущества

- Размер полученной ПП всего в  $O(\log n)$  больше размера минимальной ПП
- AVL-дерево «сильносбалансированное» дерево, его высота ограничена сверху  $\frac{1+\sqrt{5}}{2}\log n$ .

### Недостатки

• Операция перебалансировки узла является достаточно дорогой операцией, обновляется три вершины.

## Модернизация алгоритма Риттера

### Проблема

На каждой итерации алгоритм выполняется конкатенацию потенцииально огромного дерева с маленьким.

#### Основная идея

Можно соптимизировать порядок конкатенаций, уменьшив количество поворотов дерева.

#### Решение

Найти оптимальный порядок конкатенаций k деревьев можно с помощью динамического программирования за  $O(k^3)$ .

## Модернизация алгоритма Риттера

### Проблема

На каждой итерации алгоритм выполняется конкатенацию потенцииально огромного дерева с маленьким.

### Основная идея

Можно соптимизировать порядок конкатенаций, уменьшив количество поворотов дерева.

#### Решение

Найти оптимальный порядок конкатенаций k деревьев можно с помощью динамического программирования за  $O(k^3)$ .

## Модернизация алгоритма Риттера

#### Проблема

На каждой итерации алгоритм выполняется конкатенацию потенцииально огромного дерева с маленьким.

#### Основная идея

Можно соптимизировать порядок конкатенаций, уменьшив количество поворотов дерева.

#### Решение

Найти оптимальный порядок конкатенаций k деревьев можно с помощью динамического программирования за  $O(k^3)$ .

#### Мысль

- Декартово дерево двоичное дерево, в каждой вершине которого хранится ее приоритет. При этом всегда выполняется свойство: приоритет в потомках меньше, чем приоритет самой вершины.
- Доказано, что если приоритеты выбираются случайно, высота декартова дерева  $O(\log n)$ .
- Над декартовым деревом определены две стандартные операции: конкатенация и разрезание.

#### Мысль

- Декартово дерево двоичное дерево, в каждой вершине которого хранится ее приоритет. При этом всегда выполняется свойство: приоритет в потомках меньше, чем приоритет самой вершины.
- Доказано, что если приоритеты выбираются случайно, высота декартова дерева  $O(\log n)$ .
- Над декартовым деревом определены две стандартные операции: конкатенация и разрезание.

#### Мысль

- Декартово дерево двоичное дерево, в каждой вершине которого хранится ее приоритет. При этом всегда выполняется свойство: приоритет в потомках меньше, чем приоритет самой вершины.
- Доказано, что если приоритеты выбираются случайно, высота декартова дерева  $O(\log n)$ .
- Над декартовым деревом определены две стандартные операции: конкатенация и разрезание.

#### Мысль

- Декартово дерево двоичное дерево, в каждой вершине которого хранится ее приоритет. При этом всегда выполняется свойство: приоритет в потомках меньше, чем приоритет самой вершины.
- Доказано, что если приоритеты выбираются случайно, высота декартова дерева  $O(\log n)$ .
- Над декартовым деревом определены две стандартные операции: конкатенация и разрезание.

Идея алгоритма совпадает с идеей алгоритма Риттера.

#### Преимущества

- Простота реализации.
- С помощью двух операций разрезания можно получить подстроку, соответсвующую следующему фактору, одним деревом целиком.

- Высота декартова дерева на практике в два-три раза больше высоты *AVL*-дерева.
- Недетерминированность алгоритма.

Идея алгоритма совпадает с идеей алгоритма Риттера.

#### Преимущества

- Простота реализации.
- С помощью двух операций разрезания можно получить подстроку, соответсвующую следующему фактору, одним деревом целиком.

- Высота декартова дерева на практике в два-три раза больше высоты AVL-дерева.
- Недетерминированность алгоритма.

Идея алгоритма совпадает с идеей алгоритма Риттера.

#### Преимущества

- Простота реализации.
- С помощью двух операций разрезания можно получить подстроку, соответсвующую следующему фактору, одним деревом целиком.

- Высота декартова дерева на практике в два-три раза больше высоты *AVL*-дерева.
- Недетерминированность алгоритма.

Идея алгоритма совпадает с идеей алгоритма Риттера.

#### Преимущества

- Простота реализации.
- С помощью двух операций разрезания можно получить подстроку, соответсвующую следующему фактору, одним деревом целиком.

- Высота декартова дерева на практике в два-три раза больше высоты *AVL*-дерева.
- Недетерминированность алгоритма.

Идея алгоритма совпадает с идеей алгоритма Риттера.

#### Преимущества

- Простота реализации.
- С помощью двух операций разрезания можно получить подстроку, соответсвующую следующему фактору, одним деревом целиком.

- Высота декартова дерева на практике в два-три раза больше высоты *AVL*-дерева.
- Недетерминированность алгоритма.

## Практические результаты

Алгоритмы были протестированы на ДНК, взятых с сайта http://www.ddbj.nig.ac.jp/.

- Алгоритм *LZ*-факторизации. Обозначение Iz
- Алгоритм LZ77-факторизации. Обозначение Iz77
- Алгоритм Риттера. Обозначение SLPClassic
- Модернизированный алгоритм Риттера. Обозначение SLPNew
- Алгоритм построения ПП с помощью декартовых деревьев. Обозначение — **SLPCartesian**

- Алгоритм *LZ*-факторизации. Обозначение Iz
- Алгоритм *LZ*77-факторизации. Обозначение Iz**77**
- Алгоритм Риттера. Обозначение SLPClassic
- Модернизированный алгоритм Риттера. Обозначение SLPNew
- Алгоритм построения ПП с помощью декартовых деревьев.
   Обозначение SLPCartesian

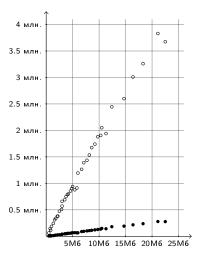
- Алгоритм LZ-факторизации. Обозначение Iz
- Алгоритм *LZ*77-факторизации. Обозначение **Iz77**
- Алгоритм Риттера. Обозначение **SLPClassic**
- Модернизированный алгоритм Риттера. Обозначение SLPNew
- Алгоритм построения ПП с помощью декартовых деревьев.
   Обозначение SLPCartesian

- Алгоритм *LZ*-факторизации. Обозначение Iz
- Алгоритм *LZ*77-факторизации. Обозначение **Iz77**
- Алгоритм Риттера. Обозначение SLPClassic
- Модернизированный алгоритм Риттера. Обозначение SLPNew
- Алгоритм построения ПП с помощью декартовых деревьев.
   Обозначение SLPCartesian

- Алгоритм *LZ*-факторизации. Обозначение Iz
- Алгоритм LZ77-факторизации. Обозначение Iz77
- Алгоритм Риттера. Обозначение SLPClassic
- Модернизированный алгоритм Риттера. Обозначение SLPNew
- Алгоритм построения ПП с помощью декартовых деревьев.
   Обозначение SLPCartesian

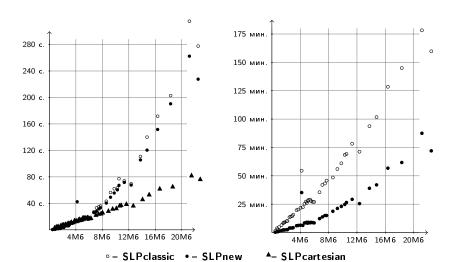
- Алгоритм *LZ*-факторизации. Обозначение Iz
- Алгоритм LZ77-факторизации. Обозначение Iz77
- Алгоритм Риттера. Обозначение SLPClassic
- Модернизированный алгоритм Риттера. Обозначение SLPNew
- Алгоритм построения ПП с помощью декартовых деревьев. Обозначение – **SLPCartesian**

## Число перебалансировок

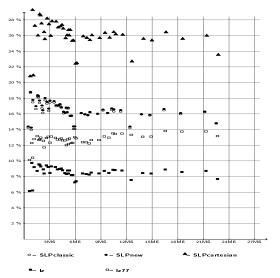


∘ - SLPclassic • - SLPnew

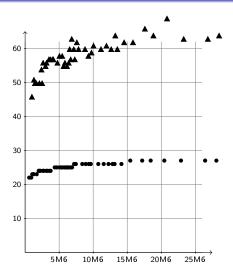
# Скорость работы на строках ДНК



## Коэффициенты сжатия



## Высоты деревьев



- Алгоритм *LZ*-факторизации с помощью суффиксного массива
- Алгоритм LZ77-факторизации с помощью суффиксного дерева
- Модернизированный алгоритм Риттера
- Алгоритм построения ПП с помощью декартовых деревьев
- Тесты

- Алгоритм *LZ*-факторизации с помощью суффиксного массива
- Алгоритм LZ77-факторизации с помощью суффиксного дерева
- Модернизированный алгоритм Риттера
- Алгоритм построения ПП с помощью декартовых деревьев
- Тесты

- Алгоритм *LZ*-факторизации с помощью суффиксного массива
- Алгоритм *LZ*77-факторизации с помощью суффиксного дерева
- Модернизированный алгоритм Риттера
- Алгоритм построения ПП с помощью декартовых деревьев
- Тесты

- Алгоритм *LZ*-факторизации с помощью суффиксного массива
- Алгоритм *LZ*77-факторизации с помощью суффиксного дерева
- Модернизированный алгоритм Риттера
- Алгоритм построения ПП с помощью декартовых деревьев
- Тесты

- Алгоритм LZ-факторизации с помощью суффиксного массива
- Алгоритм *LZ*77-факторизации с помощью суффиксного дерева
- Модернизированный алгоритм Риттера
- Алгоритм построения ПП с помощью декартовых деревьев
- Тесты

- Алгоритм LZ-факторизации с помощью суффиксного массива
- Алгоритм *LZ*77-факторизации с помощью суффиксного дерева
- Модернизированный алгоритм Риттера
- Алгоритм построения ПП с помощью декартовых деревьев
- Тесты

- Алгоритм факторизации, эффективный с точки зрения операций чтения-записи
- Алгоритм построения ПП, эффективный с точки зрения операций чтения-записи
- Худший случай алгоритма Риттера или уточнение оценки размера ПП

- Алгоритм факторизации, эффективный с точки зрения операций чтения-записи
- Алгоритм построения ПП, эффективный с точки зрения операций чтения-записи
- Худший случай алгоритма Риттера или уточнение оценки размера ПП

- Алгоритм факторизации, эффективный с точки зрения операций чтения-записи
- Алгоритм построения ПП, эффективный с точки зрения операций чтения-записи
- Худший случай алгоритма Риттера или уточнение оценки размера ПП

- Алгоритм факторизации, эффективный с точки зрения операций чтения-записи
- Алгоритм построения ПП, эффективный с точки зрения операций чтения-записи
- Худший случай алгоритма Риттера или уточнение оценки размера ПП

- Алгоритм факторизации, эффективный с точки зрения операций чтения-записи
- Алгоритм построения ПП, эффективный с точки зрения операций чтения-записи
- Худший случай алгоритма Риттера или уточнение оценки размера ПП

# Вопросы?